

台灣電力需求預測模型分析報告

1. 前言

本報告旨在探討使用機器學習模型預測台灣電力需求的可行性。透過分析包含多個相關特徵的歷史電力數據，我們訓練並評估了四種不同的迴歸模型：決策樹 (Decision Tree)、隨機森林 (Random Forest)、極限梯度提升 (XGBoost) 和支持向量回歸 (Support Vector Regression)。本報告將詳細介紹資料、方法、實驗結果以及對結果的討論。

2. 資料

本研究使用了名為 `electricity.csv` 的資料集。該資料集包含多個與電力需求相關的特徵，例如工業生產指數 (IPI)、平均溫度 (AverageTemp)、出口訂單金額 (ExportOrderAmount) 等。在進行模型訓練之前，我們對資料進行了初步的處理，包括移除 `Time`、`WEP` 和 `MEP` 等與預測目標關聯性較低的欄位。

資料集被劃分為訓練集和測試集，其中前 264 個樣本用於訓練模型，後續的 24 個樣本用於評估模型的預測性能。

3. 方法

本研究採用了以下四種機器學習迴歸模型：

*****決策樹 (Decision Tree):**** 一種基於樹狀結構進行決策的非線性模型。我們使用網格搜索 (GridSearchCV) 對決策樹的 `min\_samples\_split`、`min\_samples\_leaf`、`max\_depth` 和 `max\_features` 等超參數進行了調整。

*****隨機森林 (Random Forest):**** 一種集成學習方法，透過建立多個決策樹並取其平均預測結果來提高模型的泛化能力。我們使用網格搜索調整了 `min\_samples\_split`、

`min\_samples\_leaf`、`max\_depth`、`n\_estimators` 和 `max\_features` 等超參數。

*****極限梯度提升 (XGBoost):**** 一種高效且可擴展的梯度提升框架。我們使用網格搜索調整了 `min\_samples\_split`、`n\_estimators`、`max\_depth`、`min\_child\_weight`、`max\_features` 和 `learning\_rate` 等超參數。

*****支持向量回歸 (Support Vector Regression, SVR):**** 一種基於支持向量機的迴歸模型。由於 SVR 對特徵的尺度較為敏感，我們在訓練前對特徵進行了 Min-Max 標準化。我們使用網格搜索調整了 `kernel`、`C`、`gamma`、`epsilon` 和 `degree` 等超參數。

對於每個模型，我們都使用了 3 折交叉驗證在訓練集上進行超參數的選擇。

4. 實驗結果

4.1 模型性能評估


	DT	RF	XGB	SVR
Training				
RMSE	702350.857	590623.623	311125.993	621094.986
MAE	573599.940	474263.973	240952.168	458053.984
MAPE	0.029	0.024	0.012	0.023
	DT	RF	XGB	SVR
Testing				
RMSE	1267123.166	871522.507	896584.870	936875.276
MAE	1011939.998	700758.080	766364.103	689334.170
MAPE	0.044	0.029	0.032	0.030

上表總結了四種模型在訓練集和測試集上的性能指標：均方根誤差 (RMSE)、平均絕對誤差 (MAE) 和平均絕對百分比誤差 (MAPE)。

4.2 特徵重要性

下表列出了決策樹、隨機森林和 XGBoost 模型中最重要特徵及其重要性得分：

****決策樹特徵重要性：****(以圖表顯示)



****隨機森林特徵重要性：****(累積百分比顯示)

	Features	...	Cumulative Importance (%)
0	ImportTotalValue	...	53.48
1	PM10	...	72.89
2	ExportOrderAmount	...	80.50
3	IPI	...	86.79
4	AverageTemp	...	92.53
5	SeasonIndex	...	97.93
6	CPI	...	98.96
7	ImportTotalValue_MachineryandEquipment	...	99.64
8	ImportPriceIndex	...	100.00
9	CCI	...	100.00
10	WindSpeed	...	100.00
11	Humidity	...	100.00
12	ExportPriceIndex	...	100.00
13	RegularWage	...	100.00


****XGBoost 特徵重要性：****(按重要性排序)

Feature importance:		
	Features	Importance
5	ImportTotalValue	0.534763
7	PM10	0.194152
4	ExportOrderAmount	0.076057
0	IPI	0.062892
3	AverageTemp	0.057418
9	SeasonIndex	0.053998
2	CPI	0.010352
13	ImportTotalValue_MachineryandEquipment	0.006813
11	ImportPriceIndex	0.003554
1	CCI	0.000000
6	WindSpeed	0.000000
8	Humidity	0.000000
10	ExportPriceIndex	0.000000
12	RegularWage	0.000000


4.3 可視化結果

以下圖表展示了模型的預測結果：


****圖 1：實際值 vs. 預測值時間序列圖****




****圖 2：決策樹 - 預測值 vs. 實際值散點圖**** 殘差圖




****圖 3：隨機森林 - 預測值 vs. 實際值散點圖**** 殘差圖



****圖 4：XGBoost - 預測值 vs. 實際值散點圖**** 殘差圖



****圖 5：支持向量回歸 - 預測值 vs. 實際值散點圖**** 殘差圖



5. 討論

根據實驗結果，我們可以觀察到不同模型在電力需求預測任務上的表現各異。比較測試集上的性能指標，可以評估哪種模型更適合用於預測未來的電力需求。

從特徵重要性分析中，我們可以了解哪些特徵對模型的預測結果影響最大，這對於理解電力需求的驅動因素非常有價值。

時間序列圖可以直觀地比較模型的預測趨勢與實際需求的變化。散點圖則顯示了預測值與實際值之間的相關性，理想情況下，散點應集中在對角線附近。殘差圖則可以幫助我們判斷模型的誤差是否呈現特定的模式，這有助於我們進一步改進模型。

6. 結論與未來工作

本研究成功地應用了四種不同的機器學習模型來預測台灣的電力需求。實驗結果提供了對不同模型性能的比較，並揭示了影響電力需求的重要因素。

未來的工作可以包括：

- * 探索更多相關的特徵，例如天氣預報、節假日等。
- * 嘗試更複雜的時間序列模型或集成學習方法。
- * 進一步優化模型超參數，或嘗試不同的模型架構。
- * 對預測結果進行更深入的分析，例如預測誤差的分布和時間特性。